

# Inférence causale

Mettre votre nom

07 October 2021

Approche contrefactuelle de l'inférence causale

Résultats potentiels

Randomisation de l'assignation du traitement

Études aléatoires vs. observationnelles

# Pourquoi les chercheurs en sciences sociales et les décideurs politiques doivent-ils se soucier de la causalité ?

- ▶ [Discussion avec vos propres exemples.]

# Approche contrefactuelle de l'inférence causale

# Récents changements dans la recherche en sciences sociales

- ▶ Historiquement, la causalité inverse et le biais de variable omise ont posé problème pour la recherche en sciences sociales qui prétend expliquer les causes.
- ▶ Récemment, l'approche contrefactuelle a été adoptée dans les sciences sociales comme cadre d'inférence causale.
- ▶ Cela représente un grand changement dans la recherche :
  - ▶ Être plus précis sur ce que nous entendons par effet causal.
  - ▶ Utilisation de la randomisation ou de designs approchants.
  - ▶ Plus de partenariats entre chercheurs et praticiens.

“X cause Y” est une affirmation sur ce qui ne s’est pas produit

- ▶ Dans l’approche contrefactuelle : “Si X ne s’était pas produit, alors Y ne se serait pas produit.”
- ▶ Les expériences nous aident à en apprendre davantage sur les affirmations de causalité contrefactuelles ou dues à une manipulation lors d’une expérience.
- ▶ Ce n’est pas incorrect de *conceptualiser* la “cause” d’une autre manière. Mais il a été productif de travailler dans ce cadre contrefactuel (Brady 2008).

# Comment interpréter “X cause Y” dans cette approche

1. “X cause Y” n’implique pas nécessairement que W et V ne causent pas Y. X fait partie de l’histoire, mais ce n’est pas toute l’histoire. (Toute l’histoire n’est pas nécessaire pour savoir si X cause Y).
2. “X cause Y” nécessite un **contexte** : une allumette provoque une flamme mais cela nécessite de l’oxygène ; les petites salles de classe améliorent les résultats mais nécessitent des enseignants expérimentés et un financement adapté ([Cartwright and Hardie 2012](#)).
3. “X cause Y” peut signifier “Avec X, la probabilité de Y est plus élevée qu’elle ne le serait sans X.” ou “Sans X, il n’y a pas de Y.” Les deux sont compatibles avec l’idée contrefactuelle.

# Comment interpréter “X cause Y” dans cette approche

4. Il n'est pas nécessaire de connaître le mécanisme pour établir que X cause Y. Le mécanisme peut être complexe, et il peut impliquer des probabilités : X cause Y parfois à cause de A et parfois à cause de B.
5. La causalité contrefactuelle ne nécessite pas “une séquence spatiotemporelle continue d'intermédiaires causaux”
  - ▶ Ex : la personne A planifie l'événement Y. L'action de la personne B arrêterait Y (i.e. B va bousculer A dans la rue). La personne C ne connaît pas la personne A ou l'action Y mais arrête B (elle pense peut-être que B va trébucher). Ainsi, la personne A effectue l'action Y. Et la personne C provoque l'action Y (sans l'action de la personne C, Y n'aurait pas eu lieu)
6. Corrélation n'est pas causalité.



## Exercice : Échinacée

- ▶ Votre ami dit que la prise d'échinacée (un remède traditionnel) réduit la durée des rhumes.
- ▶ Si nous adoptons une approche contrefactuelle, que revendique implicitement cet énoncé à propos du fait contrefactuel ? Quels autres faits contrefactuels pourraient être possibles et pourquoi ?

## Résultats potentiels

# Résultats potentiels

- ▶ Pour chaque unité, nous supposons qu'il y a deux résultats **post-traitement** :  $Y_i(1)$  et  $Y_i(0)$ .
- ▶  $Y_i(1)$  est le résultat qu'on **obtiendrait** si l'unité recevait le traitement ( $T_i = 1$ ).
- ▶  $Y_i(0)$  est le résultat qu'on **obtiendrait** si l'unité recevait le traitement ( $T_i = 0$ ).

# Définition de l'effet causal

- ▶ L'**effet causal** du traitement (par rapport au contrôle) est :  
 $\tau_i = Y_i(1) - Y_i(0)$
- ▶ Notez que nous utilisons maintenant  $T$  pour indiquer notre traitement (ce dont nous voulons apprendre l'effet).  $X$  sera utilisé pour les variables d'arrière-plan TODO background variables.

# Principales caractéristiques de cette définition de l'effet causal

1. Vous devez définir la condition de contrôle pour définir un effet causal.
  - ▶ Disons que  $T = 1$  signifie une réunion communautaire pour discuter de santé publique. Est-ce que  $T = 0$  signifie pas réunion ? Est-ce que  $T = 0$  signifie une réunion sur un autre sujet ? Est-ce que  $T = 0$  est un dépliant sur la santé publique ?
  - ▶ L'expression "effet causal de  $T$  sur  $Y$ " n'a pas de sens sans savoir ce que signifie ne pas avoir  $T$ .
2. Chaque unité  $i$  a son propre effet causal  $\tau_i$ .
3. Mais nous ne pouvons pas mesurer l'effet causal au niveau individuel, car nous ne pouvons pas observer à la fois  $Y_i(1)$  et  $Y_i(0)$  en même temps. C'est ce qu'on appelle le **problème fondamental de l'inférence causale**. Ce que nous observons est  $Y_i$  :

$$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$$

Imaginons qu'on connaisse à la fois  $Y_i(1)$  et  $Y_i(0)$  (ce qui n'est jamais vrai !)

$i$	$Y_i(1)$	$Y_i(0)$	$\tau_i$
Andrei	1	1	0
Bamidele	1	0	1
Claire	0	0	0
Deepal	0	1	-1

- ▶ Nous avons l'effet du traitement pour chaque individu.
- ▶ Notez l'hétérogénéité des effets du traitement au niveau individuel.
- ▶ Mais nous n'avons au plus qu'un résultat potentiel pour chaque individu, ce qui signifie que nous ne connaissons pas ces effets du traitement.

# Effet causal moyen

- ▶ Bien que nous ne puissions pas mesurer l'effet causal individuel,  $\tau_i = Y_i(1) - Y_i(0)$ , nous pouvons affecter au hasard des sujets aux conditions de traitement et de contrôle pour estimer l'**effet causal moyen**,  $\bar{\tau}_i$ :

$$\bar{\tau}_i = \frac{1}{N} \sum_{i=1}^N (Y_i(1) - Y_i(0)) = \overline{Y_i(1) - Y_i(0)}$$

- ▶ L'effet causal moyen est également appelé effet moyen du traitement.
- ▶ Plus d'explications sur la randomisation de l'assignation du traitement dans la section suivante.

# Estimandes et questions causales

- ▶ Avant de discuter de la randomisation et de la façon dont elle nous permet d'estimer l'effet causal moyen, sachez que l'effet causal moyen est un type d'estimande.
- ▶ Un estimande est une quantité que vous souhaitez connaître (à partir de vos données). C'est la cible de votre recherche que *vous* avez définie.
- ▶ Être précis pour votre question de recherche, c'est être précis pour votre estimande. Pour les questions causales, il s'agit de préciser :
  - ▶ Le résultat
  - ▶ Les conditions de traitement et de contrôle
  - ▶ La population étudiée



## D'autres types d'estimandes

- ▶ L'effet causal moyen pour un sous-groupe particulier, i.e. effet causal moyen conditionnel
- ▶ Différences d'effet causal moyen conditionnel : différences d'effet moyen du traitement pour un groupe par rapport à un autre groupe.
- ▶ L'effet causal moyen seulement pour le groupe de traitement
- ▶ L'effet causal moyen local. “Local” = ceux dont le statut de traitement serait modifié par un encouragement dans un design incitatif (i.e. effet causal moyen conforme) ou ceux au voisinage d'un seuil pour une régression sur discontinuité.
- ▶ Les estimandes sont discutés en détail dans le module [estimandes et estimateurs](#).

# Randomisation de l'assignation du traitement

# Randomisation de l'assignation du traitement

- ▶ La randomisation signifie que chaque observation a une probabilité connue d'assignation aux conditions expérimentales *entre* 0 et 1.
  - ▶ Aucune unité de l'échantillon expérimental n'est assignée avec certitude au traitement (probabilité = 1) ou au contrôle (probabilité = 0).
- ▶ Les unités peuvent varier dans leur probabilité d'assignation au traitement.
  - ▶ Par exemple, la probabilité peut varier selon le groupe : les femmes peuvent avoir une probabilité de 25% d'être assignées au traitement tandis que les hommes ont une probabilité différente.
  - ▶ Cela peut même varier d'un individu à l'autre, même si cela compliquerait votre analyse.

# Assignment aléatoire vs. échantillonnage aléatoire

- ▶ Randomisation (du traitement) : assigner des sujets avec une probabilité connue à des conditions expérimentales.
  - ▶ Cette assignation aléatoire du traitement peut être combinée avec tout type d'échantillon (échantillon aléatoire, échantillon de convenance, etc.).
  - ▶ Mais la taille et d'autres caractéristiques de votre échantillon affecteront votre puissance statistique et votre capacité à extrapoler votre découverte à d'autres populations.
- ▶ Échantillonnage aléatoire (à partir de la population) : sélectionner des sujets dans votre échantillon à partir d'une population avec une probabilité connue.

# La randomisation est puissante (1)

- ▶ Nous cherchons l'ATE,  $\bar{\tau}_i = \overline{Y_i(1) - Y_i(0)}$ .
- ▶ Nous allons utiliser le fait que la moyenne des différences est égale à la différence des moyennes :

$$ATE = \overline{Y_i(1) - Y_i(0)} = \overline{Y_i(1)} - \overline{Y_i(0)}$$

## La randomisation est puissante (2)

- ▶ Assignons *au hasard* certaines de nos unités à la condition de traitement. Pour ces unités traitées, nous mesurons le résultat  $Y_i | T_i = 1$ , qui est le même que  $Y_i(1)$  pour ces unités.
- ▶ Parce que ces unités ont été assignées au hasard au traitement, ces  $Y_i = Y_i(1)$  pour les unités traitées représentent les  $Y_i(1)$  pour toutes nos unités.
- ▶ En espérance (ou en moyenne sur des expériences répétées (écrit  $E_R[\cdot]$ )) :

$$E_R[\overline{Y_i} | T_i = 1] = \overline{Y_i(1)}.$$

- ▶  $\overline{Y} | T_i = 1$  est un estimateur sans biais de la moyenne des résultats potentiels pour la population sous traitement.
- ▶ La même logique s'applique pour les unités affectées aléatoirement au contrôle :

$$E_R[\overline{Y_i} | T_i = 0] = \overline{Y_i(0)}.$$

## La randomisation est puissante (3)

- ▶ Nous pouvons donc écrire un estimateur pour l'effet moyen du traitement :

$$\hat{\tau}_i = (\overline{Y_i(1)} | T_i = 1) - (\overline{Y_i(0)} | T_i = 0)$$

- ▶ En espérance (ou en moyenne sur des expériences répétées,  $\hat{\tau}_i$  égal l'effet moyen du traitement :

$$E_R[Y_i | T_i = 1] - E_R[Y_i | T_i = 0] = \overline{Y_i(1)} - \overline{Y_i(0)}.$$

- ▶ Nous pouvons donc simplement prendre la différence de ces estimateurs sans biais  $\overline{Y_i(1)}$  et  $\overline{Y_i(0)}$  pour obtenir une estimation non biaisée de l'effet moyen du traitement.

# Échantillonnage aléatoire



Figure 1: Échantillon aléatoire des foyers



# Résultats potentiels

Chaque foyer  $i$  a  $Y_i(1)$  et  $Y_i(0)$ .



# Assignment aléatoire à la condition rouge (1) ou bleue (0)



Figure 2: Assignment aléatoire de cet échantillon aléatoire des foyers

# Trois hypothèses clés

Pour faire des postulats de causalité avec une expérience (ou pour juger si nous croyons aux affirmations d'une étude), nous avons besoin de trois hypothèses de base :

- ▶ Assignation aléatoire des sujets au traitement, ce qui implique que la réception du traitement est statistiquement indépendante des résultats potentiels des sujets.
- ▶ l'hypothèse SUTVA (Hypothèse stable de la valeur de traitement d'une unité / Stable unit treatment value assumption).
- ▶ L'excluabilité, ce qui signifie que les résultats potentiels d'un sujet ne répondent qu'au traitement défini, et non à d'autres facteurs externes pouvant être corrélés avec le traitement.

# Hypothèses clé : SUTVA, partie 1

1. La non-interférence – Le résultat potentiel d'un sujet reflète uniquement la réception du traitement par ce sujet. Il n'est pas affecté par la façon dont les traitements sont attribués à d'autres sujets.
  - ▶ Une violation classique est le cas des vaccins et de leurs effets de débordement.
  - ▶ Imaginons que je sois dans le groupe contrôle (pas de vaccin). Le risque de tomber malade ( $Y_i(0)$ ) dépend de l'état de traitement des autres personnes (si elles prennent le vaccin ou non), c'est comme si j'avais deux  $Y_i(0)$  différents !
  - ▶ l'hypothèse SUTVA.

# Hypothèses clé : SUTVA, partie 2

## 2. Pas de variations cachées du traitement

- ▶ Disons que le traitement consiste à prendre un vaccin, mais il existe deux types de vaccins et ils ont des compositions différentes.
- ▶ Un exemple d'infraction est le fait de tomber malade lorsque je prends le vaccin ( $Y_i(1)$ ) dépend du vaccin reçu. Nous aurions deux  $Y_i(1)$  différents !

# Hypothèses clé : l'excluabilité

- ▶ L'assignation du traitement n'a aucun effet sur les résultats, sauf par son effet sur le fait de recevoir ou non un traitement.
  - ▶ Important de définir précisément le traitement.
  - ▶ Important de maintenir la symétrie entre les groupes de traitement et de contrôle (par exemple, en aveugle, en ayant les mêmes procédures de collecte de données pour tous les sujets de l'étude, etc.), afin que l'assignation du traitement n'affecte que le traitement reçu, pas d'autres choses comme les interactions avec les chercheurs que vous ne voulez pas définir dans le cadre du traitement.

## La randomisation est puissante (4)

- ▶ Si l'intervention est aléatoire, alors recevoir ou non l'intervention n'est pas lié aux caractéristiques des bénéficiaires potentiels.
- ▶ La randomisation fait que ceux qui ont été sélectionnés au hasard pour ne pas recevoir l'intervention sont de bons remplaçants pour les contrefactuels de ceux qui ont été sélectionnés au hasard pour recevoir le traitement, et vice versa.
- ▶ Il faut s'en préoccuper si l'intervention n'était pas aléatoire (= une étude observationnelle).

## Études aléatoires vs. observationnelles



# Différents types d'études

- ▶ Études aléatoires
  - ▶ le traitement est aléatoire, ensuite on mesure les résultats
- ▶ Études d'observation
  - ▶ Le traitement n'est pas attribué au hasard. Il est observé, mais pas manipulé.

# Exercice : Apprendre de vos connaissances antérieures

**Discutez en petits groupes** : concevez le prochain projet pour répondre à l'une de ces questions (ou l'une de vos propres questions causales). Esquissez les caractéristiques clés de deux designs — un design observationnel et un design aléatoire.

## Exemples de questions de recherche :

- ▶ Les projets communautaires de reconstruction augmentent-ils la confiance et la coopération au Libéria ? [Note d'orientation des politiques publiques EGAP 40](#)
- ▶ Un suivi par la communauté peut-il augmenter le recours aux cliniques et réduire la mortalité infantile en Ouganda ? [Note d'orientation des politiques publiques EGAP 58](#)

# Exercice : études observationnelles vs études aléatoires

## Tâches :

1. Designez une étude observationnelle idéale (sans randomisation, sans contrôle par les chercheurs mais avec des ressources illimitées pour la collecte des données). Quelles questions poserait un lecteur critique lorsque vous prétendez que vos résultats reflètent une relation causale ?
2. Designez une étude aléatoire idéale (avec randomisation). Quelles questions poserait un lecteur critique lorsque vous prétendez que vos résultats reflètent une relation causale ?

# Discussion

- ▶ Quels sont les éléments clés, les forces et les faiblesses des études aléatoires ?
- ▶ Quels sont les éléments clés, les forces et les faiblesses des études observationnelles ?

# Généralisabilité et validité externe

- ▶ La randomisation apporte une validité interne élevée à une étude - nous avons appris l'effet causal du traitement sur le résultat avec un certain niveau de confiance.
- ▶ Mais le résultat d'une étude spécifique à un endroit et moment particuliers peut ne pas être valable dans d'autres contextes (i.e. la validité externe).
- ▶ C'est une préoccupation générale, pas seulement une préoccupation pour les études aléatoires.
- ▶ L'initiative Metaketa d'EGAP vise à accumuler des connaissances en pré-planifiant une méta-analyse de plusieurs études qui ont une validité interne élevée en raison de la randomisation.

# Références

Note d'orientation des politiques publiques EGAP 40 : Aide au développement et capacité d'action collective

Note d'orientation des politiques publiques EGAP 58 : La responsabilisation bottom-up fonctionne-t-elle ?

Brady, Henry E. 2008. "Causation and Explanation in Social Science." In *The Oxford Handbook of Political Science*.  
<https://www.oxfordhandbooks.com/view/10.1093/oxfordhb/9780199286546.001.0001/oxfordhb-9780199286546-e-10>.

Cartwright, Nancy, and Jeremy Hardie. 2012. *Evidence-based policy: a practical guide to doing it better*. Oxford University Press.