

# Étapes et processus du design de recherche : questions et crédibilité

Mettre votre nom

18-10-2021

Étapes et processus du design de recherche

Le processus de recherche

Le formulaire de design de recherche EGAP

DeclareDesign

Pré-enregistrement du plan d'analyse

Conclusion

Références

# Étapes et processus du design de recherche

# Qu'est-ce qui fait une bonne question de recherche ?

- ▶ La réponse à une bonne question de recherche devrait produire des connaissances qui intéresseront les gens.
- ▶ Aborder la question devrait (aider à) résoudre un problème, prendre une décision, clarifier ou remettre en cause notre compréhension du monde.
- ▶ Mais une question intéressante ne suffit pas.

# Nous avons également besoin d'un bon design de recherche

- ▶ Un bon design de recherche est un plan pratique de recherche qui utilise au mieux les ressources disponibles et produit une réponse crédible.
- ▶ La qualité d'un design de recherche peut être évaluée par la qualité des résultats produits pouvant servir à orienter les politiques et améliorer la science:
  - ▶ Un bon design de recherche produit des résultats qui pointent clairement dans des directions qui nous tiennent à cœur.
  - ▶ Un mauvais design de recherche produit des résultats qui nous laissent dans le flou — des résultats difficiles à interpréter.

# L'importance de la théorie I

Tout design de recherche implique de la théorie, qu'elle soit implicite ou explicite.

- ▶ Pourquoi faire de la recherche ? Nous avons des théories et des valeurs personnelles implicites qui guident les questions que nous posons. Nos questions sont chargées de valeurs : par exemple, les scientifiques ont étudié la consommation de marijuana dans les années 1950 comme une forme de “déviance” , les questions se concentrant sur “pourquoi les gens prennent-ils de si mauvaises décisions ?” ou “comment les décideurs politiques peuvent-ils empêcher la consommation de marijuana ?” (voir [Becker \(1998\)](#)).

# L'importance de la théorie II

- ▶ Pourquoi faire de la recherche ? Nous pourrions vouloir changer la façon dont les scientifiques expliquent le monde et/ou changer les décisions politiques (a) à un endroit et un moment donnés et/ou (b) à différents endroits et moments donnés.
- ▶ La recherche axée sur l'apprentissage de l'effet causal de  $X$  sur  $Y$  nécessite un modèle du monde: *comment* et *pourquoi* et *dans quelle proportion* l'intervention  $X$  pourrait-elle avoir un effet sur un résultat  $Y$  ? Cela nous aide à réfléchir à la façon dont une intervention différente ou des destinataires cibles différents pourraient conduire à des résultats différents.
- ▶ Nos théories et modèles sont importants non seulement pour générer des hypothèses, mais aussi pour informer sur le *design* et les *stratégies d'inférence*.

# L'importance de la théorie III

- ▶ Le design de recherche clarifie souvent les points où nous sommes moins certains de nos théories. Nos théories mettront en évidence les problèmes de notre design. Et les questions découlant de ce processus peuvent indiquer un besoin de travail supplémentaire sur l'explication et le mécanisme.



# Designer ou sélectionner votre traitement

- ▶ À partir de maintenant, nous utiliserons  $T$  pour le traitement ou ce dont nous voulons connaître l'effet. Nous utiliserons  $X$  pour faire référence aux variables.
- ▶ Votre traitement ( $T$ ) et votre contrôle (non  $T$ ) doivent être clairement liés à votre question de recherche (Voir le module sur la mesure).
- ▶ Le traitement qui vous intéresse peut être un ensemble de plusieurs composantes. Si votre question de recherche porte sur une composante spécifique, alors le contrôle doit être différent du traitement seulement pour cette composante. Tout le reste devrait être le même.

## Un exemple

Une étude où quelqu'un se rend dans une maison pour partager des informations sur la santé avec une famille pendant 15 minutes.

- ▶ Si vous êtes intéressé par l'effet de l'information spécifique, alors votre contrôle devrait toujours avoir toutes les autres composantes (visite à domicile d'une durée de 15 minutes, visiteur similaire, etc.) mais apporter des informations différentes. Ce design ne vous apprendra rien sur l'effet des visites, juste sur l'effet de l'information.
- ▶ Si votre question porte sur l'effet des visites, alors vous avez besoin d'un groupe témoin sans visite. Mais ce design ne pourra répondre à des questions spécifiques sur l'information (les visites et les informations sont regroupées).

# Interprétation

- ▶ Parfois, il n'est pas possible de traiter séparément une composante spécifique de votre traitement.
- ▶ Par exemple, votre organisme partenaire de santé dans la communauté qui se rend dans les maisons peut ne pas être intéressé à partager d'autres informations. Alors, votre contrôle pourrait être aucune visite.
- ▶ Vous devez veiller à interpréter vos effets comme l'effet de l'information délivrée de cette manière particulière.
- ▶ Vous ne pourrez pas conclure que vous avez estimé l'effet de l'information seule.
  - ▶ Cela peut convenir à certaines fins de politiques publiques : peut-être que la question porte sur les visites en tant qu'ensemble implicite de traitement.
  - ▶ Mais il est difficile d'interpréter les résultats de ce design pour affirmer quelque chose de clair sur l'information seule.

## Le processus de recherche

# Un aperçu du processus de recherche

- ▶ Articulez et affinez votre question (en vous demandant pourquoi vous posez cette question et ce qui se passera en fonction des différents types de réponses possibles).
- ▶ Développez votre design de recherche.
- ▶ Planifiez votre analyse, énoncez et justifiez les hypothèses spécifiques et enregistrez-le pour que d'autres personnes puissent le comprendre.
- ▶ Mettez en œuvre votre intervention et collectez des données.
- ▶ Analysez vos données et rédigez vos résultats.

## Le formulaire de design de recherche EGAP

# Le formulaire de design de recherche EGAP

- ▶ Nous avons développé un formulaire de design de recherche EGAP qui aide à fournir une structure pour un bon design de recherche
  - ▶ <https://egap.github.io/learningdays-resources/Exercises/design-form.Rmd>
- ▶ Cela peut aider pour
  - ▶ rédiger une proposition de recherche lors de votre demande de financement
  - ▶ élaborer un plan de pré-enregistrement

# Sections du formulaire de design de recherche EGAP

- ▶ Question de recherche
- ▶ Échantillon
- ▶ Traitement
- ▶ Résultat
- ▶ Stratégie de randomisation
- ▶ Implémentation
- ▶ Puissance statistique
- ▶ Analyse et interprétation



# Question de recherche et motivation

- ▶ Quelle est la motivation réelle de cette recherche ? Quel problème essayez-vous de résoudre ? Quelle décision essayez-vous de prendre ?
- ▶ Quelles opinions essayez-vous de changer, et que croient-ils actuellement ?
- ▶ À quelles questions théoriques générales cette recherche peut-elle aider à répondre ?
- ▶ Énoncez votre question de recherche en une phrase.
- ▶ Quelle est votre hypothèse principale ?

# Échantillon

- ▶ Où et quand aura lieu votre étude ?
- ▶ Qui/que sont les unités dans votre étude ?
- ▶ Comment cet échantillon est-il sélectionné ?
- ▶ Certaines unités doivent-elles être exclues de l'étude, car elles doivent recevoir un traitement; ou pour des raisons logistiques ou autres ?
- ▶ Vous attendez-vous à ce que le traitement fonctionne différemment pour certains sous-groupes ?

# Traitement

- ▶ Quel est votre traitement ? Avez-vous plusieurs traitements ?
- ▶ Quelle sera votre condition de contrôle ? Contrôle pur ou placebo ?
- ▶ Y a-t-il des problèmes éthiques avec le traitement ?
- ▶ À quel niveau allez-vous randomiser le traitement ?

# Résultat

- ▶ Quelle est votre résultat principal ?
- ▶ Comment allez-vous le mesurer ?
- ▶ De quelles données avez-vous besoin ? À quel niveau la mesure est-elle disponible ?
- ▶ Quels sont vos présupposés sur le résultat ? Cela peut provenir d'études antérieures ou de suppositions éclairées.
- ▶ Combien de séries de données allez-vous collecter ?
- ▶ Comment minimiserez-vous l'attrition ?
- ▶ Comment minimiserez-vous les erreurs de mesure et les résultats rapportés peu fiables ?

# Stratégie de randomisation

- ▶ Quel type de stratégie de randomisation utiliserez-vous ?  
Exemples : simple, complète, par bloc, par grappe (cluster), factorielle, à deux niveaux, par étape, etc.
- ▶ Assurez-vous que cette stratégie est cohérente avec le niveau de randomisation (clusters possibles) et l'hétérogénéité attendue des effets du traitement (blocs possibles).
- ▶ Spécifiez vos blocs et clusters (le cas échéant). Combien en aurez-vous ? De quelle taille ?
- ▶ L'interférence est-elle un sujet de préoccupation ? Si oui, comment vos stratégies d'échantillonnage et de randomisation minimiseront-elles les interférences ?

# Implémentation I

- ▶ Comment ferez-vous la randomisation réelle ? En public, en tirant au sort ? Sur un ordinateur ?
- ▶ Qui mettra en œuvre le traitement ?
- ▶ S'il y a un partenaire qui mettra en œuvre le traitement, comment vous êtes-vous arrangés ?
- ▶ Quels sont les challenges logistiques ? Des challenges particuliers pour les unités de controle ?

# Implémentation II

- ▶ Comment suivrez-vous la qualité de la mise en œuvre ?
- ▶ Comment suivrez-vous l'observance du traitement ?
- ▶ Comment minimiserez-vous le non-respect du traitement ? (le cas échéant)
- ▶ Comment allez-vous vérifier la qualité de vos données ?
- ▶ Comment les données seront-elles anonymisées et stockées en toute sécurité ? (le cas échéant)

# Puissance

- ▶ Quelle taille d'effet attendez-vous ?
  - ▶ Cela peut provenir d'une étude précédente ou d'une taille cible en dessous de laquelle on ne serait pas intéressé par de futures interventions.
- ▶ Calcul de la puissance statistique.
  - ▶ Si vous avez des clusters, il y a des problèmes supplémentaires en rapport avec la corrélation intra-cluster.



# Analyse et interprétation

- ▶ Quelle est votre estimande ? (e.g., effet moyen du traitement, effet moyen local du traitement, etc.)
- ▶ Quel est votre estimateur ? (e.g., différence des moyennes, méthode des moindres carrés pondérés par bloc, autre type de clustering). Notez que cela doit être étroitement lié à votre design de randomisation.
- ▶ Si vous trouvez que vos résultats sont cohérents avec votre hypothèse, quelles explications alternatives pourrait-il y avoir ? Quelles données vous aideraient à distinguer votre explication des autres ?
- ▶ Si vous trouvez que vos résultats ne sont pas cohérents avec votre hypothèse, quelles données vous aideront à comprendre ce qui a pu se passer ?

# DeclareDesign

# Introduction à DeclareDesign

- ▶ DeclareDesign est un package en R.
- ▶ Aide à être concret sur les étapes du design de recherche en nous permettant de les représenter en code, ce qui nous permet ensuite de simuler ces étapes afin de comprendre les propriétés des estimateurs statistiques et des tests utilisés.
- ▶ Pour voir plus (<https://declaredesign.org/getting-started>)
- ▶ Voir également le module sur les estimandes et les estimateurs qui utilise DeclareDesign pour déterminer les estimateurs corrects.

# Introduction à DeclareDesign

- ▶ Voir <https://declaredesign.org/>
- ▶ Quelle que soit la méthode, les designs de recherche comportent quatre composantes
- ▶ MEDR:
  - ▶ M : Modèle (comment fonctionne le monde)
  - ▶ E : Enquête
  - ▶ D : Stratégie de données
  - ▶ R : Stratégie de réponse
- ▶ Réflexion critique : la simulation d'un design de recherche renseigne sur les réponses qu'un design de recherche peut trouver
- ▶ Travailler avec des données simulées *avant la collecte de données* permet d'éviter les erreurs et les oublis.

# Modèle

- ▶ Un modèle sur la façon dont nous pensons que le monde fonctionne, y compris :
  - ▶  $T$ s et  $X$ s (les traitements ou les variables causales focales comme les interventions et d'autres variables contextuelles)
  - ▶  $Y$ s (les variables dépendantes)
  - ▶ Relations entre les variables (résultats potentiels, formes fonctionnelles, contexte et variables auxiliaires)
  - ▶ Distribution de probabilité par rapport aux  $X$ s et/ou  $Y$ s.
- ▶ C'est la théorie !
  - ▶ Codée numériquement.
- ▶ Le modèle est faux par définition. Si c'était correct, vous n'auriez pas besoin de faire l'étude.
- ▶ Mais sans modèle, nous n'avons pas de point de départ pour évaluer ce qui peut être appris.

# Enquête

- ▶ Une question à laquelle on peut répondre.
- ▶ Quel est l'effet d'un traitement  $T$  sur un résultat  $Y$  ?
- ▶ Généralement une quantité qui nous intéresse, un résumé des données :
  - ▶ Descriptive : quelle est la moyenne de  $Y$  traité, formellement.
  - ▶ Causale : quelle serait la différence moyenne de  $Y$  si nous échangeons traitement et contrôle ? Si nous prétendions que  $T$  ne peut pas causer  $Y$ , avons-nous des preuves de cette affirmation ?
  - ▶ La quantité est l'estimande ou l'hypothèse.
- ▶ Toutes les questions que nous voulons poser n'ont pas de réponse.
  - ▶ Et l'éventail des questions que nous pouvons poser est limité : que pouvons-nous apprendre à partir d'une quantité sommaire telle que l'effet moyen du traitement ?

# Données

- ▶ Réaliser (générer) des données sur l'ensemble des variables (tous les  $X$ s,  $T$ s et  $Y$ s)
- ▶ Une fonction de votre modèle
- ▶ Comprend à la fois:
  - ▶ l'échantillonnage — comment les unités arrivent dans votre échantillon ?
  - ▶ l'assignation du traitement — quelles valeurs des variables endogènes sont révélées ?

# Réponse

- ▶ À partir d'un jeu de données, générer une réponse – une estimation de la quantité d'intérêt (enquête)
- ▶ Ceci est votre estimateur ou votre test:
  - ▶ Différence des moyennes
  - ▶ Test- $t$
  - ▶ Méthodes de régression
  - ▶ etc.
- ▶ La réponse est une estimation de la quantité d'intérêt ou de la  $p$ -valeur (enquête/estimande/test)



## Pré-enregistrement du plan d'analyse

# Biais de publication dans la recherche contre les résultats nuls

- ▶ Anticiper ou faire face aux difficultés de publication : les manuscrits avec des résultats nuls ne sont jamais soumis pour examen ou sont mis au placard après plusieurs refus.
- ▶ Nous sommes tous incités à modifier nos spécifications, mesures ou même hypothèses pour obtenir un résultat statistiquement significatif (le *p*-hacking) pour améliorer nos chances de parution.
- ▶ Même les personnes qui ne sont pas confrontées à ce problème prennent de nombreuses décisions lorsqu'elles analysent des données : traitement des valeurs manquantes et des observations en double, création d'échelles, etc. Et ces choix peuvent être conséquents.
- ▶ Résultat global : crédibilité réduite pour la recherche individuelle et confiance réduite (à juste titre) quant à savoir si nous savons réellement ce que nous prétendons savoir.

# Vers une revue du design plutôt que des résultats

- ▶ Pour résoudre partiellement ce problème, se concentrer sur le design plutôt que sur les résultats.
- ▶ Le biais de publication contre les résultats nuls peut être surmonté en examinant le design en amont des résultats.
- ▶ Un bon design bien exécuté produira une recherche crédible, qui pourrait être un résultat nul. Nous voulons des résultats nuls crédibles et exploitables.
- ▶ Les revues de design sont aussi une opportunité d'améliorer la recherche avant sa réalisation.

# Pré-enregistrement du plan d'analyse et design de recherche I

- ▶ Le pré-enregistrement est le dépôt de votre design de recherche et de vos hypothèses auprès d'un répertoire public. EGAP en héberge un que vous pouvez utiliser gratuitement (actuellement sur [OSF.io](https://osf.io) en utilisant le formulaire d'inscription EGAP).
- ▶ Le pré-enregistrement n'exclut pas les analyses exploratoires ultérieures qui n'ont pas été déclarées à l'avance. Il suffit de bien distinguer les deux.

# Pré-enregistrement du plan d'analyse et design de recherche II

- ▶ Même si vous soumettez un article avec des résultats plutôt qu'un design à une revue scientifique ou si vous êtes principalement intéressé par un rapport final avec des conclusions pour un audience politique, il y a des avantages importants pour vous et pour les autres chercheurs à pré-inscrire votre recherche.
  - ▶ Vous pouvez vous renseigner sur d'autres recherches, terminées et en cours; d'autres peuvent en apprendre davantage sur la vôtre. Nous pouvons apprendre des études non concluantes.
  - ▶ Cela vous oblige à énoncer vos hypothèses et votre plan d'analyse avant de voir les résultats, ce qui limite le  $p$ -hacking.

## Conclusion

# Le processus de recherche : questions, théorie et crédibilité

- ▶ La recherche commence avec nos valeurs et nos théories sur le fonctionnement du monde.
- ▶ Cela se poursuit en articulant des questions qui peuvent être clairement abordées par l'observation (dans notre cas, en utilisant l'expérimentation aléatoire).
- ▶ Les bonnes questions ont des visées conséquentes : amener une explication scientifique ou des décisions politiques différentes.
- ▶ Les bons designs cochent toutes les cases et donnent aux lecteurs des raisons de croire aux résultats.
- ▶ Les checklists (comme le formulaire de design de recherche ou de pré-enregistrement) aident à éviter les erreurs d'inattention.
- ▶ Le pré-enregistrement augmente encore la crédibilité et donc les chances que vos résultats aient un impact scientifique ou politique.

## Références



# Références

Becker, Howard S. 1998. *Tricks of the Trade : How to Think about Your Research While You're Doing It (Chicago Guides to Writing, Editing, and Publishing)*. University Of Chicago Press.